

Revisão do Pré-projeto

Disciplina: Trabalho de Conclusão de Curso I – BCC

Caro, orientando,

segue abaixo o Termo de Compromisso, as DUAS revisões do seu pré-projeto contendo a avaliação do professor “avaliador” e professor “TCC1”, junto com as avaliações da defesa na banca de qualificação. É muito importante que revise com cuidado e discuta possíveis dúvidas decorrente das revisões com o seu professor orientador, e com o professor de TCC1. Sempre procure fazer todos os ajustes solicitados, até mesmo os menores detalhes, pois todos são importantes e irão refletir na sua nota nesta disciplina. Lembre de abrir localmente em um visualizador PDF para poder ver as anotações que foram feitas. E, aparecendo uma anotação feita por mim (prof. De TCC1) que inicie com “TF-...” (ex. “TF-ALÍNEA”) se refere a ajustes de formatação indicando que deve usar o estilo do Word correto do modelo do projeto.

Mas, caso o professor orientador julgue que algumas anotações das revisões não devam ser feitas, ou mesmo que sejam feitas de forma diferente a solicitada pelo revisor, anexe ao final do seu projeto a ficha “Projeto: Observações – Professor Orientador” disponível no material da disciplina, e justifique o motivo.

Lembrem que agora o limite de páginas do projeto é no máximo 12 (doze) páginas. E que a seção de “Revisão Bibliográfica” deve ser complementada (ampliada) usando subseções para cada assunto apresentado.

Atenciosamente,

TERMO DE COMPROMISSO - BCC

I – IDENTIFICAÇÃO DO ALUNO	
Nome:	Jeferson Bonecher
Telefone:	(47) 99275-8895
II – IDENTIFICAÇÃO DO TRABALHO	
Título:	ANÁLISE COMPARATIVA DE ALGORITMOS DE MACHINE LEARNING PARA A PREVISÃO DE VALOR DAS AÇÕES NA BOLSA DE VALORES.
Orientador:	Marcel Hugo
Coorientador (se houver):	
III – COMPROMISSO DE REALIZAÇÃO DO TCC	
Eu (aluno),	Jeferson Bonecher
comprometo-me a realizar o trabalho proposto no semestre <u>2023/2</u> , de acordo com as normas e os prazos determinados pela FURB, conforme previsto na resolução nº.20/2016.	
IV – COMPROMISSO DE ORIENTAÇÃO	
Eu (orientador),	Marcel Hugo
comprometo-me a orientar o trabalho proposto no semestre <u>2023/2</u> , de acordo com as normas e os prazos determinados pela FURB, conforme previsto na resolução nº.20/2016.	

CURSO DE CIÊNCIA DA COMPUTAÇÃO – TCC		
(X) PRÉ-PROJETO	() PROJETO	ANO/SEMESTRE: 2023/1

ANÁLISE COMPARATIVA DE ALGORITMOS DE MACHINE LEARNING PARA A PREVISÃO DE VALOR DAS AÇÕES NA BOLSA DE VALORES

Jeferson Bonecher

Prof. Marcel Hugo – Orientador

1 INTRODUÇÃO

A bolsa de valores é um ambiente centralizado e especializado voltado para negociações no mercado de capitais, onde empresas e empreendimentos ofertam seus títulos, ações e instrumentos financeiros com o objetivo de atrair investidores e agentes interessados (ALMEIDA, 2022). Essa plataforma de negociações permite às organizações captar recursos para financiar projetos e expandir atividades, enquanto investidores individuais e institucionais buscam diversificar seus portfólios e obter retornos financeiros através da compra e venda desses ativos. A bolsa de valores também promove a liquidez, eficiência, segurança e transparência do mercado, garantindo a integridade das operações realizadas entre os participantes.

Segundo Pinto (2020) uma das formas de fazer uma análise de um ativo é através da Análise Técnica. Ela é muito utilizada por investidores e profissionais do mercado financeiro para prever a direção dos preços de determinados ativos financeiros, com base na análise de gráficos que mostram a movimentação desses ativos ao longo do tempo. Por meio desta análise busca-se identificar padrões e tendências que possam indicar movimentos futuros e, assim, tomar decisões de "entrada" e "saída" com base nessas informações. A Análise Técnica é especialmente útil para operações de curto prazo na Bolsa de Valores, já que permite tomar decisões rápidas que podem resultar em lucro ou prejuízo em questão de minutos ou segundos, a depender da volatilidade do ativo em questão.

No campo da Análise Técnica, os algoritmos de machine learning, incluindo Redes Neurais Recorrentes (RNRs), têm ganhado cada vez mais espaço devido à sua capacidade de processar e analisar grandes volumes de dados em tempo real (XP Education, 2023). As RNRs são particularmente eficazes na análise de sequências temporais, como os dados de mercado financeiro, já que possuem a habilidade de capturar dependências temporais de longo prazo. Essa abordagem permite que investidores e traders identifiquem padrões e tendências nos mercados financeiros, auxiliando na tomada de decisões e potencialmente melhorando os resultados de suas operações (Matsumoto, 2019).

Nesse sentido, o presente trabalho tem como proposta realizar uma análise comparativa entre as redes neurais recorrentes Gated Recurrent Unit (GRU) e Long Short-Term Memory (LSTM) na previsão de valores de ações na bolsa de valores brasileira. Para tanto, serão utilizados dados históricos de empresas listadas na B3, buscando identificar qual dos algoritmos apresenta as melhores taxa de acerto para previsão dos preços das ações.

1.1 OBJETIVOS

O objetivo deste trabalho é realizar uma comparação entre as redes neurais recorrentes LSTM e GRU para determinar qual delas apresenta o melhor desempenho na previsão dos preços das ações de cinco empresas listadas na bolsa de valores brasileira.

Os objetivos específicos são:

- coletar e organizar os dados históricos de preços das ações das empresas Weg, Petrobras, Copel, Vale e Magazine Luiza na bolsa de valores brasileira;
- implementar e treinar redes neurais recorrentes GRU e LSTM para prever os preços de fechamento das ações das empresas selecionadas;
- avaliar o desempenho dos algoritmos GRU e LSTM utilizando métricas como acurácia, Mean Squared Error (MSE), Mean Absolute Error (MAE), Mean Absolute Percentage Error (MAPE) e Root Mean Squared Error (RMSE).

2 TRABALHOS CORRELATOS

Nesta seção serão apresentados os trabalhos que correlacionam com o principal objetivo do presente trabalho. A subseção 2.1 traz o trabalho desenvolvido por Rossi (2019), em que foi criado um protótipo capaz de prever valores de ações através de Redes Neurais Artificiais. Na subseção 2.2 é apresentado um protótipo que prevê o preço das ações por meio de notícias (Bezerra, 2022). Na subseção 2.3 está uma aplicação com o objetivo de prever valores de ações através de RNRs (Ribeiro et al. 2021).

Comentado [AFH1]: Quem disse isso

Comentado [AFH2]: Paragrafos 1 e 2 sem conexão

Comentado [AFH3]: Frase desnecessária

Comentado [AFH4]: Quem disse isso?

Comentado [AFH5]: Uhm... Não tenho certeza disso... Para trabalhar com séries, acho que sim!

Comentado [AFH6]: Verificar formatação

Comentado [AFH7]: Verificar formatação

Comentado [AFH8]: Acho que isso é requisito

2.1 PROTÓTIPO PARA PREVISÃO DE AÇÕES UTILIZANDO REDES NEURAIS ARTIFICIAIS

O trabalho desenvolvido por Rossi (2019) tem como objetivo criar um protótipo capaz de prever tendências de preços de ações no mercado financeiro, utilizando Redes Neurais Artificiais (RNA) com foco na arquitetura LSTM. O intuito é fornecer uma ferramenta que auxilie investidores na tomada de decisões mais informadas ao realizar investimentos em ações na Bolsa de Valores. Os resultados foram satisfatórios atingindo uma taxa de 70% de acerto para o movimento ocorrido na semana.

Segundo Rossi (2019), o processo envolve diversas etapas, começando pela coleta de dados históricos das ações, que incluem preço de fechamento, preço de abertura, preço máximo, preço mínimo e volume negociado, a partir de fontes públicas. Os dados são, então, normalizados para que a amplitude das variações não afete o processo de treinamento e previsão da RNA. O conjunto de dados é dividido em subconjuntos de treinamento e teste, sendo que o primeiro é usado para treinar o modelo e o segundo para avaliar seu desempenho. A técnica de validação cruzada é aplicada para garantir a generalização do modelo e evitar o sobreajuste. Durante esse processo, o conjunto de treinamento é dividido em várias partições, e o modelo é treinado em cada uma delas, excluindo uma partição que é utilizada como conjunto de validação. A média dos resultados obtidos em todas as partições é utilizada como estimativa final do desempenho do modelo.

De acordo com Rossi (2019), para avaliar a eficácia do modelo proposto em situações reais, foram selecionadas cinco ações de alta liquidez e frequentemente negociadas na bolsa de valores: Raia Drogasil (RADL3), Vale SA (VALE3), Bradesco (BBDC4), Petrobras (PETR4) e WEG SA (WEGE3). Utilizando um período diário, o modelo empregou os últimos 50 valores de fechamento para prever os próximos 5 preços. A avaliação do desempenho do modelo foi realizada durante o treinamento da LSTM, utilizando as métricas de erro MSE e MAE. Os resultados obtidos podem ser observados na Tabela 1.

Tabela 1- Cálculos de erro durante o treinamento (em R\$)

	RADL3	VALE3	BBDC4	PETR4	WEGE3
MSE	0,00046	0,00077	0,00083	0,00085	0,00035
MAE	0,01600	0,01970	0,02150	0,02020	0,01350

Fonte: Rossi (2019).

Os resultados mostraram que as ações RADL3 e WEGE3 obtiveram os melhores desempenhos, conforme apresentado na Tabela 2. O modelo conseguiu prever corretamente a tendência de alta ou baixa nas cotações em 7 das 10 semanas avaliadas. Por outro lado, as ações VALE3 e BBDC4 apresentaram os piores resultados, com uma taxa de acerto de 30% e 40% na previsão, respectivamente. Essa diferença de desempenho pode ser atribuída à alta volatilidade desses ativos.

Tabela 2 – Taxa de acerto das movimentações

Ação	Taxa de acerto
RADL3	70%
VALE3	30%
BBDC4	40%
PETR4	60%
WEGE3	70%

Fonte: Rossi (2019).

2.2 REDES NEURAIS ARTIFICIAIS NA PREVISÃO DO PREÇO DAS AÇÕES NA BOLSA DE VALORES POR MEIO DE NOTÍCIAS

Bezerra (2022) apresenta um protótipo que utiliza redes neurais artificiais para sugerir a compra ou venda de ativos negociados na Bolsa de Valores brasileira, com base em notícias do mercado financeiro. O protótipo usa uma base de dados de 10.766 notícias coletadas através de um *Web Scraper*, com dados das empresas Banco do Brasil (BBAS3), PetroRIO (PRIO3) e Vale do Rio Doce (VALE3) no período de 01/01/2018 a 20/05/2022. A eficácia do protótipo foi avaliada com um percentual de acurácia de 52% nos testes.

De acordo com Bezerra (2022), o estudo examinou o efeito das notícias do mercado corporativo das três empresas nos preços das ações, observando os valores na abertura, no fechamento e no dia subsequente. O sentimento das notícias foi classificado como positivo quando o preço das ações aumentou e negativo quando diminuiu. Para analisar a relação entre as notícias e os preços das ações, empregou-se um algoritmo de classificação binária, designando 0 para reações negativas e 1 para reações positivas. Os achados indicaram que a previsão dos dados não é linear, e os gráficos evidenciaram a volatilidade do mercado, particularmente no período analisado (2018-2022). A Tabela 3 exibiu o total de sentimentos positivos e negativos relacionados às notícias e a quantidade total de notícias para cada empresa.

Comentado [AFH9]: Passado pois já foi desenvolvido em 2019

Comentado [AFH10]: Acho que falta uma parte do trabalho... Você focou apenas na parte da LSTM... Mas, também tem o front-end

Comentado [AFH11]: Deve ser mais para baixo!

Comentado [AFH12]: Tempo verbal

Comentado [AFH13]: Não seria, o desempenho da etapa de treinamento...

Comentado [AFH14]: Aqui falta referência

Comentado [AFH15]: Acho que você poderia utilizar os gráficos do artigo ao invés das tabelas..

Comentado [AFH16]: No artigo, tem esta parte que é bem importante.

"Para mensuração da acurácia, foram estabelecidas 10 semanas de teste, contemplando um período ideal, tendo em vista que o mercado passou por altas e baixas. A validação ocorreu através do cálculo do Valor-P, provando que todas as cinco ações tiveram resultados estatisticamente significantes, indicando com fortes evidências de que os resultados não são devido ao acaso. "

Comentado [AFH17]: Não sei se é interessante colocar este trabalho envolvendo RNA. Nos portais científicos existem vários e vários trabalhos envolvendo LSTM e GRU

Na verdade, acho que a descrição do trabalho precisa ser ajustada... Este é o resumo do trabalho. Ao ele menciona o uso de PLN e LSTM

Investir na bolsa de valores pode representar excelentes oportunidades financeiras, o que impulsiona pesquisadores e investidores a prever o mercado financeiro. Este trabalho tem como objetivo geral disponibilizar um protótipo usando Redes Neurais Artificiais e Processamento de Linguagem Natural para sugerir a compra ou venda de ativos negociados na Bolsa de Valores brasileira, por meio de notícias do mercado financeiro, a fim de auxiliar investidores nas suas transações no mercado de renda variável. Para isso, 10.766 notícias foram usadas como base de dados de aprendizagem do protótipo, advindas das empresas BBAS3, PRIO e VALE3, no período 01/01/2018 e 20/05/2022. Utilizou-se Redes Neurais Artificiais Long Short-Term Memory (LSTM) para fazer as previsões e a Matriz de Confusão para avaliação da eficácia do protótipo. O percentual de acurácia do protótipo alcançou 52% e a ferramenta disponibiliza cadastro e acesso dos usuários ao projeto, bem como apresenta os resultados do modelo preditivo aos interessados em investir no mercado financeiro. Sugere-se que as melhorias no protótipo avaliem as variações mais significativas dos preços das ações investigando o número de notícias interfere na eficácia do modelo preditivo.

Comentado [AFH18]: Não é aqui..

Comentado [AFH19]: O que o Fabricio utilizou em termos de técnica para fazer a classificação

Tabela 3 – Sentimentos positivos e negativos em relação às notícias das empresas pesquisadas

Empresas	Notícias Positivas	Notícias Negativas	Total
BAS3	1.975	1.903	3.878
PRI0	352	310	662
VALE3	3.181	3.045	6.226
TOTAL	5.508	5.258	10.776

Fonte: Bezerra (2022).

Segundo Bezerra (2022), os resultados obtidos apresentados na Tabela 4, destacam o recall das variáveis positivas para PetroRio (0,57) e Banco do Brasil (0,53), bem como a precision, que alcançou o mesmo valor (0,52) em todas as empresas. Entretanto, o F1-Score, que mede a efetividade geral do modelo, não ultrapassou 52% para BBAS3 e VALE3, e atingiu apenas 0,45 para PetroRio. Essa baixa efetividade pode estar relacionada ao baixo número de notícias da empresa no período analisado e sugere um foco investigativo futuro.

Tabela 4 – Relatório de Classificação do Protótipo na Matriz Confusão

Empresa	Resultados	Precision	Recall	F1-Score	Support
Banco do Brasil	0 = Negativo	0.51	0.50	0.51	385
	1 = Positivo	0.52	0.53	0.53	391
	Acurácia			0.52	776
	Macro avg	0.52	0.52	0.52	776
	Weighted avg	0.52	0.52	0.52	776
PetroRio	0 = Negativo	0.33	0.29	0.30	56
	1 = Positivo	0.52	0.57	0.35	77
	Acurácia			0.45	133
	Macro avg	0.43	0.43	0.43	133
	Weighted avg	0.44	0.45	0.44	133
Vale do Rio Doce	0 = Negativo	0.52	0.53	0.52	624
	1 = Positivo	0.52	0.51	0.52	622
	Acurácia			0.52	1.246
	Macro avg	0.52	0.52	0.52	1.246
	Weighted avg	0.52	0.52	0.52	1.246

Fonte: Bezerra (2022).

2.3 PREVISÃO DE PREÇO DE AÇÕES BASEADA EM REDES NEURAIS RECORRENTES LSTM E GRU

Ribeiro *et al.* (2021) conduziram uma pesquisa com o objetivo de prever os valores das ações no mercado brasileiro, empregando redes neurais recorrentes, tais como LSTM e GRU. Diversos cenários foram estabelecidos, combinando as referidas redes neurais a métricas de análise técnica, como médias móveis e bandas de Bollinger. Utilizaram-se dados do Yahoo Finance para criar cenários variáveis, buscando aprimorar as previsões dos valores futuros das ações. Métricas de erro, como MAPE, RMSE e U de Theil, foram empregadas na avaliação do desempenho dos modelos, auxiliando na tomada de decisões relativas aos investimentos. A pesquisa optou pela biblioteca Keras devido à sua eficiência e facilidade de uso, sendo desenvolvida em linguagem Python.

De acordo com Ribeiro *et al.* (2021), a rede LSTM possui 4 camadas com 100, 80 e 50 unidades nas três primeiras camadas, respectivamente, e uma camada de saída com 1 unidade, todas com uma taxa de Dropout de 0.2. O algoritmo de otimização utilizado é o Adam. Já a rede GRU é composta por 5 camadas, sendo 4 delas com 50 unidades e 0.2 de Dropout, e a camada de saída com 1 unidade. O algoritmo de otimização usado é o SGD. Ambas as redes utilizam o erro médio quadrático como métrica de perda.

Com isso, Ribeiro *et al.* (2021) desenvolveu diferentes cenários para cada uma das ações selecionadas???, tanto às redes LSTM quanto às redes GRU. O objetivo era verificar o desempenho das redes não apenas com os valores das séries temporais, mas também considerando outras variáveis (*features*), como volume de transações diárias e valor de fechamento do Índice Bovespa. Foram utilizadas variáveis conhecidas do mercado financeiro para análise técnica, como médias móveis e bandas de Bollinger. As variáveis escolhidas para os cenários estão apresentadas na Tabela 03.

Comentado [AFH20]: Mesma coisa, você poderia apresentar os gráficos. Rever descrição deste artigo...

Comentado [AFH21]: No trabalho, o autor especifica as ações (p.30)

Comentado [AFH22]: Não é aqui

Tabela 03 – Variáveis relacionadas aos cenários utilizados

Cenários	Variáveis
0	Close
1	Close, Volume, Close_bovespa, Volume_bovespa
2	Close, Volume, Close_bovespa, Volume_bovespa, MA3, MA7, MA20, MA30, MA60, CMA3, ST3, ST7, ST20, ST30, ST60, UPPER3, LOWER3, UPPER7, LOWER7, UPPER20, LOWER20, UPPER30, LOWER30, UPPER60, LOWER60
3	Close, Volume, Close_bovespa, Volume_bovespa, MA3, MA30, MA60, CMA3, ST3, ST30, ST60, UPPER3, LOWER3, UPPER30, LOWER30, UPPER60, LOWER60
4	Close, Volume, Close_bovespa, Volume_bovespa, MA3, CMA3, ST3, UPPER3, LOWER3

Fonte: Ribeiro *et al.* (2021).

Para Ribeiro *et al.* (2021), os resultados indicaram que, de maneira geral, a inclusão de *features* adicionais aprimorou o desempenho das redes LSTM, resultando em médias mais baixas de erro percentual. Em relação às redes GRU, embora não tenha havido um cenário que se sobressaísse em todas as empresas analisadas, os resultados apontam que as *features* podem ser consideradas boas opções de métricas para previsões de valores de ações, devido ao baixo valor da média de erro percentual encontrado.

3 PROPOSTA

Nesta seção será descrita a proposta deste trabalho, justificando o desenvolvimento, definindo os requisitos funcionais e não funcionais, as metodologias abordadas e por fim o cronograma.

3.1 JUSTIFICATIVA

No Quadro 1 é apresentado um comparativo entre os trabalhos correlatos. As linhas representam as características e as colunas os trabalhos.

Quadro 1 - Comparativo dos trabalhos correlatos

Trabalhos Correlatos Características	Rossi (2019)	Bezerra (2022)	Ribeiro <i>et al.</i> (2021)
RNRs utilizadas	LSTM	LSTM	LSTM, GRU
Métricas utilizadas	MSE, MAE	Precision, Recall, f1-score	MAPE, RMSE U DE THEIL
Ações analisadas	RADL3, VALE3, BBDC4, PETR4, WEGE3	BBAS3, VALE3, PRIO3	AMBEV, VALE3, BBDC4, PETR4, ITUB4
Histórico de preço	Sim	Não	Sim
Taxa de acerto	70%	52%	-
Disponibilizada interface de consulta	Sim	Sim	Não

Fonte: elaborado pelo autor.

Conforme pode ser observado no Quadro 1, os trabalhos correlatos apresentados utilizam redes neurais recorrentes para analisar ações no mercado financeiro. Rossi (2019) e Bezerra (2022) usam LSTM como arquitetura de RNR, enquanto Ribeiro *et al.* (2021) empregam tanto LSTM quanto GRU. As métricas utilizadas para avaliar o desempenho são diferentes entre os estudos: Rossi (2019) utiliza MSE e MAE, Bezerra (2022) emprega Precision, Recall e f1-score, enquanto Ribeiro *et al.* (2021) usam MAPE, RMSE e U de Theil. Com estas métricas eles comparam as duas arquiteturas utilizadas junto com as quatro variáveis para definir qual rede teve o melhor desempenho. Os três estudos analisam diferentes conjuntos de ações, VALE3 sendo utilizada por todos.

Comentado [AFH23]: No trabalho, os autores discutem e apresentam uns gráficos, etc..

Comentado [AFH24]: Inverter a ordem das linhas... Primeiro as bases e depois modelo e avaliação

Comentado [AFH25]: Não citada na descrição do trabalho

Comentado [AFH26]: Ao invés de sim ou não, deveria ser descrito a características... Qtos dias analisados e para frente

Comentado [AFH27]: Falta uma linha com as variáveis analisadas...

Apenas Rossi (2019) e Bezerra (2022) utilizam métricas mostrando sua taxa de acerto em porcentagem sendo 70% e 52% respectivamente. Ribeiro et al. (2021) utiliza outras métricas para medir seu desempenho e também é o único que não disponibiliza interface de consulta para seu modelo.

Esta proposta é relevante e significativa, pois aborda a complexidade da análise de ações no mercado financeiro e busca melhorar as técnicas existentes utilizando RNRs, como LSTMs e GRUs. Essas arquiteturas são capazes de capturar padrões temporais e extrair informações relevantes em séries temporais, tornando-as adequadas para o contexto do mercado financeiro. A investigação de diferentes métricas de desempenho, assim como a análise de conjuntos variados de ações, pode gerar percepções valiosas sobre a efetividade das RNRs na previsão do comportamento das ações e, conseqüentemente, auxiliar na otimização das estratégias de investimento.

As contribuições do estudo abrangem aspectos teóricos e práticos. Teoricamente, o estudo expande o conhecimento sobre a eficácia de diferentes arquiteturas de RNRs, como LSTMs e GRUs, na análise de ações e a relevância de distintas métricas de desempenho na avaliação de modelos de previsão no contexto do mercado financeiro. Em termos práticos, com base nas descobertas teóricas, o estudo oferece diretrizes para o desenvolvimento de modelos de análise de ações mais eficientes e precisos, resultando em melhores estratégias de investimento e auxiliando investidores e profissionais do mercado financeiro na tomada de decisões mais embasadas e potencialmente lucrativas.

3.2 REQUISITOS PRINCIPAIS DO PROBLEMA A SER TRABALHADO

A ferramenta a ser desenvolvida deve:

- a) gerar a previsão do valor de fechamento diário das ações -(Requisito Funcional - RF);
- b) gerar gráficos das previsões de valores das ações (RF);
- c) gerar métricas definidas para comparar os dois algoritmos (RF);
- d) ser implementada utilizando a linguagem Python (Requisito Não Funcional - RNF);
- e) importar os dados históricos das ações através da biblioteca Yahoo Finance (RNF);
- f) ser capaz de processar todo os históricos disponíveis dos preços das ações (RNF);
- g) utilizar a biblioteca TensorFlow (RNF);
- h) ser modelada seguindo os princípios das RNRs (RNF).

3.3 METODOLOGIA

O trabalho será desenvolvido observando as seguintes etapas:

- a) levantamento bibliográfico: buscar fontes bibliográficas com relação as RNRs, e bem como buscar trabalhos correlatos;
- b) elicitação de requisitos da aplicação, baseando-se nas informações da etapa anterior, reavaliar os requisitos propostos para a aplicação;
- c) processamento dos dados: importação e processamento dos dados utilizando a média dos preços de abertura, fechamento, preço mais alto e mais baixo em cada período de análise;
- d) preparação dos dados para modelagem: os dados processados serão divididos em conjuntos de treinamento e teste, e serão normalizados para garantir que os algoritmos de machine learning possam aprender com eficiência;
- e) implementação dos algoritmos: nesta etapa, serão implementadas as RNRs GRU e LSTM;
- f) treinamento e validação dos modelos: os modelos GRU e LSTM serão treinados usando os conjuntos de treinamento e validação. Serão ajustados os hiperparâmetros para obter o melhor desempenho possível;
- g) avaliação dos modelos: após o treinamento, os modelos serão avaliados no conjunto de teste com base em métricas como acurácia, MSE, MAE, MAPE e RMSE;
- h) comparação dos algoritmos: nesta etapa, os resultados dos modelos GRU e LSTM serão comparados com base nas métricas obtidas.

As etapas serão realizadas nos períodos relacionados no Quadro 2.

Comentado [AFH28]: Acho que não!

Comentado [AFH29]: Uhm... chatgpt

Comentado [AFH30]: Será uma ferramenta?

Comentado [AFH31]: Gerar métricas... Ou seria utilizar métricas... E quais?

Comentado [AFH32]: Bem... Aqui você deveria indicar os dias de análises (passados e futuros)

Comentado [AFH33]: Você não cita LSTM ou GRU aqui...

Comentado [AFH34]: Talvez você precise limpar e normalizar os dados... Definir variáveis, bases a serem consideradas...

Comentado [AFH35]: Mercado de ações não será necessário?

Comentado [AFH36]: Aqui você indicar limpeza, nos requisitos não

Comentado [AFH37]: Rever... Estas etapas estão confusas

Comentado [AFH38]: Na verdade, você utilizará... Através do tensorflow/keras

Comentado [AFH39]: Este item aqui, quebra um pouco a importância do teu trabalho... Neste caso, serão umas 20linhas para indicar qual método é melhor

Comentado [AFH40]: rever

Quadro 2 - Cronograma

etapas / quinzenas	2023									
	ago.		set.		out.		nov.		dez.	
	1	2	1	2	1	2	1	2	1	2
levantamento bibliográfico										
elicitación										
processamento dos dados										
preparação dos dados para modelagem										
implementação dos algoritmos										
treinamento e validação dos modelos										
avaliação dos modelos										
comparação dos algoritmos										

Fonte: elaborado pelo autor.

Comentado [AFH41]: Dezembro não deve ser colocado no cronograma!

4 REVISÃO BIBLIOGRÁFICA

Esta seção descreve brevemente sobre os assuntos que fundamentarão o estudo a ser realizado: **Análise Técnica de ações e Redes Neurais Recorrentes.**

Segundo Hochreiter e Schmidhuber (1997) a LSTM (Long Short-Term Memory) é uma arquitetura de aprendizado de máquina que aprimora as redes neurais recorrentes (RNRs) ao incorporar uma memória de longa duração, permitindo que o modelo compreenda a importância relativa das informações ao longo do tempo e aprenda e retenha informações relevantes de um passado mais remoto. Essa característica habilita as LSTMs a efetuar previsões mais precisas em diversas aplicações, como tradução automática, geração de texto e previsão de séries temporais.

De acordo com Cho et al. (2014) a GRU (Gated Recurrent Unit) é uma arquitetura de aprendizado de máquina que aperfeiçoa as redes neurais recorrentes (RNRs), incorporando mecanismos de atualização e redefinição para aprimorar a retenção de dependências temporais de longo alcance. Com uma estrutura simplificada e menor complexidade computacional em relação às LSTMs, as GRUs exibem desempenho semelhante em várias tarefas, incluindo análise de sentimentos, tradução automática e previsão de séries temporais.

Para avaliar o desempenho das RNRs normalmente serão utilizadas métricas de erro, como o MAE, que calcula a média dos valores absolutos das diferenças entre previsões e valores reais; o MSE, que dá mais peso aos maiores erros por meio da média das diferenças quadráticas; e o RMSE, que é a raiz quadrada do MSE e retorna o erro à unidade de medida do modelo. Além disso, o MAPE é uma métrica útil em previsão de demanda, mostrando a porcentagem média de erro em relação aos valores reais e calculando a soma dos valores absolutos das diferenças pelo valor absoluto dos valores reais, multiplicando o resultado por 100 (OLIVEIRA JÚNIOR, 2021).

Comentado [AFH42]: Acho que é a primeira vez que aparece no texto com esta denominação.. Também não é descrito abaixo ou menciona na etapa 1 da metodologia

REFERÊNCIAS

ALMEIDA, Guilherme. **Bolsa de Valores: entenda tudo sobre esse mercado.** [2022]. Disponível em: <https://www.certifiquei.com.br/bolsa-valores/>. Acesso em: 20 abr. 2023.

Bezerra, Fabrício Oliveira. **Redes Neurais Artificiais na Previsão do Preço das Ações na Bolsa de Valores por Meio de Notícias.** [2022]. Trabalho de Conclusão de Curso (Bacharelado em Ciência da Computação) - Centro de Ciências Exatas e Naturais, Universidade Regional de Blumenau, Blumenau.

CHO, Kyunghyun; MERRIENBOER, Bart van; GULCEHRE, Caglar; BOUGARES, Fethi; SCHWENK, Holger; BENGIO, Yoshua. **Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation.** In: Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP). Doha, Qatar: Association for Computational Linguistics, 2014. p. 1724-1734. Disponível em: <https://www.aclweb.org/anthology/D14-1179.pdf>. Acesso em: 15 mar. 2023.

HOCHREITER, Sepp; SCHMIDHUBER, Jürgen. **Long short-term memory.** *Neural Computation*, v. 9, n. 8, p. 1735-1780, 1997. [1997]. Disponível em: <https://www.bioinf.jku.at/publications/older/2604.pdf>. Acesso em: 18 abr. 2023.

Matsumoto, Daniel K.F. **Estudo em Séries Temporais Financeiras utilizando Redes Neurais Recorrentes.** 2019. Disponível em: <https://www.repositorio.ufal.br/bitstream/riufal/6813/3/Estudo%20em%20s%C3%A9ries%20temporais%20financeiras%20utilizando%20redes%20neurais%20recorrentes.pdf>. Acesso em: 20 abr. 2023.

OLIVEIRA JÚNIOR, Clébio de. **Métricas para Regressão: Entendendo as métricas R², MAE, MAPE, MSE e RMSE.** [2021]. Disponível em: <https://medium.com/data-hackers/prevendo-n%C3%BAmeros-entendendo-m%C3%A9tricas-de-regress%C3%A3o-35545e011e70>. Acesso em: 19 abr. 2022.

PINTO, Leonardo. **O que é análise técnica: confira o guia completo.** [2020]. Disponível em: <https://conteudos.xpi.com.br/aprenda-a-investir/relatorios/o-que-e-analise-tecnica/>. Acesso em: 22 abr. 2023.

RIBEIRO, Marcos Vinicius de Oliveira; CORREA, Matheus Morgado. **Previsão de Preço de Ações Baseada em Redes Neurais Recorrentes LSTM e GRU**. [2021]. Disponível em: <https://app.uff.br/riuff/bitstream/handle/1/26733/Matheus%20MorgadoTCC%20Marcos%20e%20%20final.pdf?sequence=1&isAllowed=y>. Acesso em: 10 mar. 2023.

ROSSI, Rafael Bertoldi. **Protótipo para previsão de ações utilizando redes neurais artificiais**. [2019]. Trabalho de Conclusão de Curso (Bacharelado em Ciência da Computação) - Centro de Ciências Exatas e Naturais, Universidade Regional de Blumenau, Blumenau.

XP Education. **O machine learning pode ser utilizado no mercado financeiro? Vem que a gente explica!** [S.l.], [2023]. Disponível em: <https://blog.xpeducacao.com.br/machine-learning-no-mercado-financeiro/>. Acesso em: 22 abr. 2023.

FORMULÁRIO DE AVALIAÇÃO BCC – PROFESSOR AVALIADOR – PRÉ-PROJETO

Avaliador(a): **Aurélio Faustino Hoppe**

Atenção: quando o avaliador marcar algum item como atende parcialmente ou não atende, deve obrigatoriamente indicar os motivos no texto, para que o aluno saiba o porquê da avaliação.

ASPECTOS AVALIADOS		Atende	atende parcialmente	não atende
ASPECTOS TÉCNICOS	1. INTRODUÇÃO O tema de pesquisa está devidamente contextualizado/delimitado?	X		
	O problema está claramente formulado?	X		
	2. OBJETIVOS O objetivo principal está claramente definido e é passível de ser alcançado?	X		
	Os objetivos específicos são coerentes com o objetivo principal?	X		
	3. TRABALHOS CORRELATOS São apresentados trabalhos correlatos, bem como descritas as principais funcionalidades e os pontos fortes e fracos?	X		
	4. JUSTIFICATIVA Foi apresentado e discutido um quadro relacionando os trabalhos correlatos e suas principais funcionalidades com a proposta apresentada?	X		
	São apresentados argumentos científicos, técnicos ou metodológicos que justificam a proposta?	X		
	São apresentadas as contribuições teóricas, práticas ou sociais que justificam a proposta?	X		
	5. REQUISITOS PRINCIPAIS DO PROBLEMA A SER TRABALHADO Os requisitos funcionais e não funcionais foram claramente descritos?	X		
	6. METODOLOGIA Foram relacionadas todas as etapas necessárias para o desenvolvimento do TCC?	X		
	Os métodos, recursos e o cronograma estão devidamente apresentados e são compatíveis com a metodologia proposta?	X		
	7. REVISÃO BIBLIOGRÁFICA Os assuntos apresentados são suficientes e têm relação com o tema do TCC?	X		
ASPECTOS METODOLÓGICOS	8. LINGUAGEM USADA (redação) O texto completo é coerente e redigido corretamente em língua portuguesa, usando linguagem formal/científica?	X		
	A exposição do assunto é ordenada (as ideias estão bem encadeadas e a linguagem utilizada é clara)?			X

CURSO DE CIÊNCIA DA COMPUTAÇÃO – TCC		
(X) PRÉ-PROJETO	() PROJETO	ANO/SEMESTRE: 2023/1

ANÁLISE COMPARATIVA DE ALGORITMOS DE MACHINE LEARNING PARA A PREVISÃO DE VALOR DAS AÇÕES NA BOLSA DE VALORES

Jeferson Bonecher

Prof. Marcel Hugo – Orientador

5 INTRODUÇÃO

A bolsa de valores é um ambiente centralizado e especializado voltado para negociações no mercado de capitais, onde empresas e empreendimentos ofertam seus títulos, ações e instrumentos financeiros com o objetivo de atrair investidores e agentes interessados (ALMEIDA, 2022). Essa plataforma de negociações permite às organizações captar recursos para financiar projetos e expandir atividades, enquanto investidores individuais e institucionais buscam diversificar seus portfólios e obter retornos financeiros através da compra e venda desses ativos. A bolsa de valores também promove a liquidez, eficiência, segurança e transparência do mercado, garantindo a integridade das operações realizadas entre os participantes.

Segundo Pinto (2020) uma das formas de fazer uma análise de um ativo é através da Análise Técnica. Ela é muito utilizada por investidores e profissionais do mercado financeiro para prever a direção dos preços de determinados ativos financeiros, com base na análise de gráficos que mostram a movimentação desses ativos ao longo do tempo. Por meio desta análise busca-se identificar padrões e tendências que possam indicar movimentos futuros e, assim, tomar decisões de "entrada" e "saída" com base nessas informações. A Análise Técnica é especialmente útil para operações de curto prazo na Bolsa de Valores, já que permite tomar decisões rápidas que podem resultar em lucro ou prejuízo em questão de minutos ou segundos, a depender da volatilidade do ativo em questão.

No campo da Análise Técnica, os algoritmos de ~~machine~~-Machine Learning, incluindo Redes Neurais Recorrentes (RNRs), têm ganhado cada vez mais espaço devido à sua capacidade de processar e analisar grandes volumes de dados em tempo real (XP Education, 2023). As RNRs são particularmente eficazes na análise de sequências temporais, como os dados de mercado financeiro, já que possuem a habilidade de capturar dependências temporais de longo prazo. Essa abordagem permite que investidores e *traders* identifiquem padrões e tendências nos mercados financeiros, auxiliando na tomada de decisões e potencialmente melhorando os resultados de suas operações (MATSUMOTO, 2019).

Comentado [DS43]: Maiúsculo.

Nesse sentido, o presente trabalho tem como proposta realizar uma análise comparativa entre as redes neurais recorrentes Gated Recurrent Unit (GRU) e Long Short-Term Memory (LSTM) na previsão de valores de ações na bolsa de valores brasileira. Para tanto, serão utilizados dados históricos de empresas listadas na B3 (~~bolsa de valores brasileira sediada na cidade de São Paulo~~), buscando identificar qual dos algoritmos apresenta as melhores taxa de acerto para previsão dos preços das ações.

5.1 OBJETIVOS

O objetivo deste trabalho é realizar uma comparação entre as redes neurais recorrentes LSTM e GRU para determinar qual delas apresenta o melhor desempenho na previsão dos preços das ações de cinco empresas listadas na bolsa de valores brasileira.

Os objetivos específicos são:

- coletar e organizar os dados históricos de preços das ações das empresas Weg, Petrobras, Copel, Vale e Magazine Luiza na bolsa de valores brasileira;
- implementar e treinar redes neurais recorrentes GRU e LSTM para prever os preços de fechamento das ações das empresas selecionadas;
- avaliar o desempenho dos algoritmos GRU e LSTM utilizando métricas como acurácia, Mean Squared Error (MSE), Mean Absolute Error (MAE), Mean Absolute Percentage Error (MAPE) e Root Mean Squared Error (RMSE).

6 TRABALHOS CORRELATOS

Nesta seção serão apresentados os trabalhos que correlacionam com o principal objetivo do presente trabalho. A subseção 2.1 traz o trabalho desenvolvido por Rossi (2019), em que foi criado um protótipo capaz de prever valores de ações através de Redes Neurais Artificiais. Na subseção 2.2 é apresentado um protótipo que prevê o preço das ações por meio de notícias (BEZERRA, 2022). Na subseção 2.3 está uma aplicação com o objetivo de prever valores de ações através de RNRs (RIBEIRO *et al.*, 2021).

Comentado [DS44]: Maiúsculo.

6.1 PROTÓTIPO PARA PREVISÃO DE AÇÕES UTILIZANDO REDES NEURAI ARTIFICIAIS

O trabalho desenvolvido por Rossi (2019) tem como objetivo criar um protótipo capaz de prever tendências de preços de ações no mercado financeiro, utilizando Redes Neurais Artificiais (RNA) com foco na arquitetura LSTM. O intuito é fornecer uma ferramenta que auxilie investidores na tomada de decisões mais informadas ao realizar investimentos em ações na Bolsa de Valores. Os resultados foram satisfatórios atingindo uma taxa de 70% de acerto para o movimento ocorrido na semana.

Segundo Rossi (2019) o processo envolve diversas etapas, começando pela coleta de dados históricos das ações, que incluem preço de fechamento, preço de abertura, preço máximo, preço mínimo e volume negociado, a partir de fontes públicas. Os dados são, então, normalizados para que a amplitude das variações não afete o processo de treinamento e previsão da RNA. O conjunto de dados é dividido em subconjuntos de treinamento e teste, sendo que o primeiro é usado para treinar o modelo e o segundo para avaliar seu desempenho. A técnica de validação cruzada é aplicada para garantir a generalização do modelo e evitar o sobreajuste. Durante esse processo, o conjunto de treinamento é dividido em várias partições, e o modelo é treinado em cada uma delas, excluindo uma partição que é utilizada como conjunto de validação. A média dos resultados obtidos em todas as partições é utilizada como estimativa final do desempenho do modelo.

De acordo com Rossi (2019) para avaliar a eficácia do modelo proposto em situações reais, foram selecionadas cinco ações de alta liquidez e frequentemente negociadas na bolsa de valores: Raia Drogasil (RADL3), Vale SA (VALE3), Bradesco (BBDC4), Petrobras (PETR4) e WEG SA (WEGE3). Utilizando um período diário, o modelo empregou os últimos 50 valores de fechamento para prever os próximos 5 preços. A avaliação do desempenho do modelo foi realizada durante o treinamento da LSTM, utilizando as métricas de erro MSE e MAE. Os resultados obtidos podem ser observados na Tabela 1.

Tabela 1- Cálculos de erro durante o treinamento (em R\$)

	RADL3	VALE3	BBDC4	PETR4	WEGE3
MSE	0,00046	0,00077	0,00083	0,00085	0,00035
MAE	0,01600	0,01970	0,02150	0,02020	0,01350

Fonte: Rossi (2019).

Os resultados mostraram que as ações RADL3 e WEGE3 obtiveram os melhores desempenhos, conforme apresentado na Tabela 2. O modelo conseguiu prever corretamente a tendência de alta ou baixa nas cotações em 7 das 10 semanas avaliadas. Por outro lado, as ações VALE3 e BBDC4 apresentaram os piores resultados, com uma taxa de acerto de 30% e 40% na previsão, respectivamente. Essa diferença de desempenho pode ser atribuída à alta volatilidade desses ativos.

Tabela 2 – Taxa de acerto das movimentações

Ação	Taxa de acerto
RADL3	70%
VALE3	30%
BBDC4	40%
PETR4	60%
WEGE3	70%

Fonte: Rossi (2019).

6.2 REDES NEURAI ARTIFICIAIS NA PREVISÃO DO PREÇO DAS AÇÕES NA BOLSA DE VALORES POR MEIO DE NOTÍCIAS

Bezerra (2022) apresenta um protótipo que utiliza redes neurais artificiais para sugerir a compra ou venda de ativos negociados na Bolsa de Valores brasileira, com base em notícias do mercado financeiro. O protótipo usa uma base de dados de 10.766 notícias coletadas através de um *Web Scraper*, com dados das empresas Banco do Brasil (BBAS3), PetroRIO (PRIO3) e Vale do Rio Doce (VALE3) no período de 01/01/2018 a 20/05/2022. A eficácia do protótipo foi avaliada com um percentual de acurácia de 52% nos testes.

De acordo com Bezerra (2022) o estudo examinou o efeito das notícias do mercado corporativo das três empresas nos preços das ações, observando os valores na abertura, no fechamento e no dia subsequente. O sentimento das notícias foi classificado como positivo quando o preço das ações aumentou e negativo quando diminuiu. Para analisar a relação entre as notícias e os preços das ações, empregou-se um algoritmo de classificação binária, designando 0 para reações negativas e 1 para reações positivas. Os achados indicaram que a previsão dos dados não é linear, e os gráficos evidenciaram a volatilidade do mercado, particularmente no período analisado (2018-2022). A Tabela 3 exibiu o total de sentimentos positivos e negativos relacionados às notícias e a quantidade total de notícias para cada empresa.

Tabela 3 – Sentimentos positivos e negativos em relação às notícias das empresas pesquisadas

Empresas	Notícias Positivas	Notícias Negativas	Total
BAS3	1.975	1.903	3.878
PRI0	352	310	662
VALE3	3.181	3.045	6.226
TOTAL	5.508	5.258	10.776

Fonte: Bezerra (2022).

Segundo Bezerra (2022) os resultados obtidos apresentados na Tabela 4, destacam o *recall* das variáveis positivas para PetroRio (0,57) e Banco do Brasil (0,53), bem como a *precision*, que alcançou o mesmo valor (0,52) em todas as empresas. Entretanto, o F1-Score, que mede a efetividade geral do modelo, não ultrapassou 52% para BBAS3 e VALE3, e atingiu apenas 0,45 para PetroRio. Essa baixa efetividade pode estar relacionada ao baixo número de notícias da empresa no período analisado e sugere um foco investigativo futuro.

Tabela 4 – Relatório de Classificação do Protótipo na Matriz Confusão

Empresa	Resultados	Precision	Recall	F1-Score	Support
Banco do Brasil	0 = Negativo	0.51	0.50	0.51	385
	1 = Positivo	0.52	0.53	0.53	391
	Acurácia			0.52	776
	Macro avg	0.52	0.52	0.52	776
	Weighted avg	0.52	0.52	0.52	776
PetroRio	0 = Negativo	0.33	0.29	0.30	56
	1 = Positivo	0.52	0.57	0.35	77
	Acurácia			0.45	133
	Macro avg	0.43	0.43	0.43	133
	Weighted avg	0.44	0.45	0.44	133
Vale do Rio Doce	0 = Negativo	0.52	0.53	0.52	624
	1 = Positivo	0.52	0.51	0.52	622
	Acurácia			0.52	1.246
	Macro avg	0.52	0.52	0.52	1.246
	Weighted avg	0.52	0.52	0.52	1.246

Fonte: Bezerra (2022).

6.3 PREVISÃO DE PREÇO DE AÇÕES BASEADA EM REDES NEURAIIS RECORRENTES LSTM E GRU

Ribeiro *et al.* (2021) conduziram uma pesquisa com o objetivo de prever os valores das ações no mercado brasileiro, empregando redes neurais recorrentes, tais como LSTM e GRU. Diversos cenários foram estabelecidos, combinando as referidas redes neurais a métricas de análise técnica, como médias móveis e bandas de Bollinger. Utilizaram-se dados do Yahoo Finance para criar cenários variáveis, buscando aprimorar as previsões dos valores futuros das ações. Métricas de erro, como MAPE, RMSE e U de Theil, foram empregadas na avaliação do desempenho dos modelos, auxiliando na tomada de decisões relativas aos investimentos. A pesquisa optou pela biblioteca Keras devido à sua eficiência e facilidade de uso, sendo desenvolvida em linguagem Python.

De acordo com Ribeiro *et al.* (2021) a rede LSTM possui 4 camadas com 100, 80 e 50 unidades nas três primeiras camadas, respectivamente, e uma camada de saída com 1 unidade, todas com uma taxa de Dropout de 0.2. O algoritmo de otimização utilizado é o Adam. A rede GRU é composta por 5 camadas, sendo 4 delas com 50 unidades e 0.2 de Dropout, e a camada de saída com 1 unidade. O algoritmo de otimização usado é o SGD. Ambas as redes utilizam o erro médio quadrático como métrica de perda.

Com isso Ribeiro *et al.* (2021) desenvolveu diferentes cenários para cada uma das ações selecionadas, tanto às redes LSTM quanto às redes GRU. O objetivo era verificar o desempenho das redes não apenas com os valores das séries temporais, mas também considerando outras variáveis (*features*), como volume de transações diárias e valor de fechamento do Índice Bovespa. Foram utilizadas variáveis conhecidas do mercado financeiro para análise técnica, como médias móveis e bandas de Bollinger. As variáveis escolhidas para os cenários estão apresentadas na Tabela 03.

Comentado [DS45]: Itálico.

Comentado [DS46]: Itálico.

Comentado [DS47]: Tabela 5.

Tabela 03 – Variáveis relacionadas aos cenários utilizados

Cenários	Variáveis
0	Close
1	Close, Volume, Close_bovespa, Volume_bovespa
2	Close, Volume, Close_bovespa, Volume_bovespa, MA3, MA7, MA20, MA30, MA60, CMA3, ST3, ST7, ST20, ST30, ST60, UPPER3, LOWER3, UPPER7, LOWER7, UPPER20, LOWER20, UPPER30, LOWER30, UPPER60, LOWER60
3	Close, Volume, Close_bovespa, Volume_bovespa, MA3, MA30, MA60, CMA3, ST3, ST30, ST60, UPPER3, LOWER3, UPPER30, LOWER30, UPPER60, LOWER60
4	Close, Volume, Close_bovespa, Volume_bovespa, MA3, CMA3, ST3, UPPER3, LOWER3

Fonte: Ribeiro et al. (2021).

Para Ribeiro *et al.* (2021) os resultados indicaram que, de maneira geral, a inclusão de *features* adicionais aprimorou o desempenho das redes LSTM, resultando em médias mais baixas de erro percentual. Em relação às redes GRU, embora não tenha havido um cenário que se sobressaísse em todas as empresas analisadas, os resultados apontam que as *features* podem ser consideradas boas opções de métricas para previsões de valores de ações, devido ao baixo valor da média de erro percentual encontrado.

7 PROPOSTA

Nesta seção será descrita a proposta deste trabalho, justificando o desenvolvimento, definindo os requisitos funcionais e não funcionais, as metodologias abordadas e por fim o cronograma.

7.1 JUSTIFICATIVA

No Quadro 1 é apresentado um comparativo entre os trabalhos correlatos. As linhas representam as características e as colunas os trabalhos.

Quadro 3 - Comparativo dos trabalhos correlatos

Trabalhos Correlatos Características	Rossi (2019)	Bezerra (2022)	Ribeiro <i>et al.</i> (2021)
RNRs utilizadas	LSTM	LSTM	LSTM, GRU
Métricas utilizadas	MSE, MAE	Precision, Recall, f1-score	MAPE, RMSE U DE THEIL
Ações analisadas	RADL3, VALE3, BBDC4, PETR4, WEGE3	BBAS3, VALE3, PRIO3	AMBEV, VALE3, BBDC4, PETR4, ITUB4
Histórico de preço	Sim	Não	Sim
Taxa de acerto	70%	52%	-
Disponibilizada interface de consulta	Sim	Sim	Não

Fonte: elaborado pelo autor.

Conforme pode ser observado no Quadro 1, os trabalhos correlatos apresentados utilizam redes neurais recorrentes para analisar ações no mercado financeiro. Rossi (2019) e Bezerra (2022) usam LSTM como arquitetura de RNR, enquanto Ribeiro *et al.* (2021) empregam tanto LSTM quanto GRU. As métricas utilizadas para avaliar o desempenho são diferentes entre os estudos: Rossi (2019) utiliza MSE e MAE, Bezerra (2022) emprega Precision, Recall e f1-score, enquanto Ribeiro *et al.* (2021) usam MAPE, RMSE e U de Theil. Com estas métricas eles comparam as duas arquiteturas utilizadas junto com as quatro variáveis para definir qual rede teve o melhor desempenho. Os três estudos analisam diferentes conjuntos de ações, VALE3 sendo utilizada por todos.

Comentado [DS48]: Tabela 5

Comentado [DS49]: Itálico.

Comentado [DS50]: Itálico.

Apenas Rossi (2019) e Bezerra (2022) utilizam métricas mostrando sua taxa de acerto em porcentagem sendo 70% e 52% respectivamente. Ribeiro *et al.* (2021) utiliza outras métricas para medir seu desempenho e também é o único que não disponibiliza interface de consulta para seu modelo.

Comentado [DS51]: Itálico.

Esta proposta é relevante e significativa, pois aborda a complexidade da análise de ações no mercado financeiro e busca melhorar as técnicas existentes utilizando RNRs, como LSTMs e GRUs. Essas arquiteturas são capazes de capturar padrões temporais e extrair informações relevantes em séries temporais, tornando-as adequadas para o contexto do mercado financeiro. A investigação de diferentes métricas de desempenho, assim como a análise de conjuntos variados de ações, pode gerar percepções valiosas sobre a efetividade das RNRs na previsão do comportamento das ações e, conseqüentemente, auxiliar na otimização das estratégias de investimento.

As contribuições do estudo abrangem aspectos teóricos e práticos. Teoricamente, o estudo expande o conhecimento sobre a eficácia de diferentes arquiteturas de RNRs, como LSTMs e GRUs, na análise de ações e a relevância de distintas métricas de desempenho na avaliação de modelos de previsão no contexto do mercado financeiro. Em termos práticos, com base nas descobertas teóricas, o estudo oferece diretrizes para o desenvolvimento de modelos de análise de ações mais eficientes e precisos, resultando em melhores estratégias de investimento e auxiliando investidores e profissionais do mercado financeiro na tomada de decisões mais embasadas e potencialmente lucrativas.

7.2 REQUISITOS PRINCIPAIS DO PROBLEMA A SER TRABALHADO

A ferramenta a ser desenvolvida deve:

- l) gerar a previsão do valor de fechamento diário das ações- (Requisito Funcional - RF);
- m) gerar gráficos das previsões de valores das ações (RF);
- n) gerar métricas definidas para comparar os dois algoritmos (RF);
- o) ser implementada utilizando a linguagem Python (Requisito Não Funcional - RNF);
- p) importar os dados históricos das ações através da biblioteca Yahoo Finance (RNF);
- q) ser capaz de processar todo os históricos disponíveis dos preços das ações (RNF);
- r) utilizar a biblioteca TensorFlow (RNF);
- s) ser modelada seguindo os princípios das RNRs (RNF).

7.3 METODOLOGIA

O trabalho será desenvolvido observando as seguintes etapas:

- t) levantamento bibliográfico: buscar fontes bibliográficas com relação as RNRs, e bem como buscar trabalhos correlatos;
- u) elicitação de requisitos da aplicação, baseando-se nas informações da etapa anterior, reavaliar os requisitos propostos para a aplicação;
- v) processamento dos dados: importação e processamento dos dados utilizando a média dos preços de abertura, fechamento, preço mais alto e mais baixo em cada período de análise;
- w) preparação dos dados para modelagem: os dados processados serão divididos em conjuntos de treinamento e teste, e serão normalizados para garantir que os algoritmos de ~~maehine~~-Machine learning-Learning possam aprender com eficiência;
- x) implementação dos algoritmos: nesta etapa, serão implementadas as RNRs GRU e LSTM;
- y) treinamento e validação dos modelos: os modelos GRU e LSTM serão treinados usando os conjuntos de treinamento e validação. Serão ajustados os hiperparâmetros para obter o melhor desempenho possível;
- z) avaliação dos modelos: após o treinamento, os modelos serão avaliados no conjunto de teste com base em métricas como acurácia, MSE, MAE, MAPE e RMSE;
- aa) comparação dos algoritmos: nesta etapa, os resultados dos modelos GRU e LSTM serão comparados com base nas métricas obtidas.

As etapas serão realizadas nos períodos relacionados no Quadro 2.

Quadro 4 - Cronograma

etapas / quinzenas	2023									
	ago.		set.		out.		nov.		dez.	
	1	2	1	2	1	2	1	2	1	2
levantamento bibliográfico										
elicitación										
processamento dos dados										
preparação dos dados para modelagem										
implementação dos algoritmos										
treinamento e validação dos modelos										
avaliação dos modelos										
comparação dos algoritmos										

Fonte: elaborado pelo autor.

8 REVISÃO BIBLIOGRÁFICA

Esta seção descreve brevemente sobre os assuntos que fundamentarão o estudo a ser realizado: Análise Técnica de ações e Redes Neurais Recorrentes.

Segundo Hochreiter e Schmidhuber (1997) a **LSTM** (Long Short-Term Memory (**LSTM**) é uma arquitetura de aprendizado de máquina que aprimora as **redes neurais recorrentes** (RNRs) ao incorporar uma memória de longa duração, permitindo que o modelo compreenda a importância relativa das informações ao longo do tempo e aprenda e retenha informações relevantes de um passado mais remoto. Essa característica habilita as LSTMs a efetuar previsões mais precisas em diversas aplicações, como tradução automática, geração de texto e previsão de séries temporais.

De acordo com Cho *et al.* (2014) a **GRU** (Gated Recurrent Unit (**GRU**) é uma arquitetura de aprendizado de máquina que aperfeiçoa as **redes neurais recorrentes** (RNRs), incorporando mecanismos de atualização e redefinição para aprimorar a retenção de dependências temporais de longo alcance. Com uma estrutura simplificada e menor complexidade computacional em relação às LSTMs, as GRUs exibem desempenho semelhante em várias tarefas, incluindo análise de sentimentos, tradução automática e previsão de séries temporais.

Para avaliar o desempenho das RNRs serão utilizadas métricas de erro, como o MAE, que calcula a média dos valores absolutos das diferenças entre previsões e valores reais; o MSE, que dá mais peso aos maiores erros por meio da média das diferenças quadráticas; e o RMSE, que é a raiz quadrada do MSE e retorna o erro à unidade de medida do modelo. Além disso, o MAPE é uma métrica útil em previsão de demanda, mostrando a porcentagem média de erro em relação aos valores reais e calculando a soma dos valores absolutos das diferenças pelo valor absoluto dos valores reais, multiplicando o resultado por 100 (OLIVEIRA JÚNIOR, 2021).

REFERÊNCIAS

ALMEIDA, Guilherme. **Bolsa de Valores: entenda tudo sobre esse mercado**. [2022]. Disponível em: <https://www.certifiquei.com.br/bolsa-valores/>. Acesso em: 20 abr. 2023.

BEZERRA, Fabricio Oliveira. **Redes Neurais Artificiais na Previsão do Preço das Ações na Bolsa de Valores por Meio de Notícias**. [2022]. Trabalho de Conclusão de Curso (Bacharelado em Ciência da Computação) - Centro de Ciências Exatas e Naturais, Universidade Regional de Blumenau, Blumenau.

CHO, Kyunghyun; MERRIENBOER, Bart van; GULCEHRE, Caglar; BOUGARES, Fethi; SCHWENK, Holger; BENGIO, Yoshua. **Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation**. In: Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP). Doha, Qatar: Association for Computational Linguistics, 2014. p. 1724-1734. Disponível em: <https://www.aclweb.org/anthology/D14-1179.pdf>. Acesso em: 15 mar. 2023.

HOCHREITER, Sepp; SCHMIDHUBER, Jürgen. **Long short-term memory**. *Neural Computation*, v. 9, n. 8, p. 1735-1780, 1997. [1997]. Disponível em: <https://www.bioinf.jku.at/publications/older/2604.pdf>. Acesso em: 18 abr. 2023.

MATSUMOTO, Daniel K.F. **Estudo em Séries Temporais Financeiras utilizando Redes Neurais Recorrentes**. 2019. Disponível em: <https://www.repositorio.ufal.br/bitstream/riufal/6813/3/Estudo%20em%20s%C3%A9ries%20temporais%20financeiras%20utilizando%20redes%20neurais%20recorrentes.pdf>. Acesso em: 20 abr. 2023.

OLIVEIRA JÚNIOR, Clébio de. **Métricas para Regressão: Entendendo as métricas R², MAE, MAPE, MSE e RMSE**. [2021]. Disponível em: <https://medium.com/data-hackers/prevendo-n%C3%BAmoros-entendendo-m%C3%A9tricas-de-regress%C3%A3o-35545e011c70>. Acesso em: 19 abr. 2022.

PINTO, Leonardo. **O que é análise técnica: confira o guia completo**. [2020]. Disponível em: <https://conteudos.xpi.com.br/aprenda-a-investir/relatorios/o-que-e-analise-tecnica/>. Acesso em: 22 abr. 2023.

Comentado [DS52]: Itálico.

Comentado [DS53]: Maiúsculo.

Comentado [DS54]: Maiúsculo.

RIBEIRO, Marcos Vinicius de Oliveira; CORREA, Matheus Morgado. **Previsão de Preço de Ações Baseada em Redes Neurais Recorrentes LSTM e GRU.** [2021]. Disponível em: <https://app.uff.br/riuff/bitstream/handle/1/26733/Matheus%20MorgadoTCC%20Marcos%20e%20%20final.pdf?sequence=1&isAllowed=y>. Acesso em: 10 mar. 2023.

ROSSI, Rafael Bertoldi. **Protótipo para previsão de ações utilizando redes neurais artificiais.** [2019]. Trabalho de Conclusão de Curso (Bacharelado em Ciência da Computação) - Centro de Ciências Exatas e Naturais, Universidade Regional de Blumenau, Blumenau.

XP Education. **O machine learning pode ser utilizado no mercado financeiro? Vem que a gente explica!** [S.l.], [2023]. Disponível em: <https://blog.xpeducacao.com.br/machine-learning-no-mercado-financeiro/>. Acesso em: 22 abr. 2023.

Comentado [DS55]: Nas citações aparecem Ribeiro et al. (2021)
Mas são dois autores, então não seria et al.

FORMULÁRIO DE AVALIAÇÃO BCC – PROFESSOR TCC I – PRÉ-PROJETO

Avaliador(a): Dalton Solano dos Reis

ASPECTOS AVALIADOS		atende	atende parcialmente	não atende
ASPECTOS TÉCNICOS	9. INTRODUÇÃO O tema de pesquisa está devidamente contextualizado/delimitado?	X		
	O problema está claramente formulado?	X		
	10. OBJETIVOS O objetivo principal está claramente definido e é passível de ser alcançado?	X		
	Os objetivos específicos são coerentes com o objetivo principal?	X		
	11. JUSTIFICATIVA São apresentados argumentos científicos, técnicos ou metodológicos que justificam a proposta?	X		
	São apresentadas as contribuições teóricas, práticas ou sociais que justificam a proposta?	X		
	12. METODOLOGIA Foram relacionadas todas as etapas necessárias para o desenvolvimento do TCC?	X		
	Os métodos, recursos e o cronograma estão devidamente apresentados?	X		
ASPECTOS METODOLÓGICOS	13. REVISÃO BIBLIOGRÁFICA Os assuntos apresentados são suficientes e têm relação com o tema do TCC?	X		
	14. LINGUAGEM USADA (redação) O texto completo é coerente e redigido corretamente em língua portuguesa, usando linguagem formal/científica?	X		
	A exposição do assunto é ordenada (as ideias estão bem encadeadas e a linguagem utilizada é clara)?	X		
	15. ORGANIZAÇÃO E APRESENTAÇÃO GRÁFICA DO TEXTO A organização e apresentação dos capítulos, seções, subseções e parágrafos estão de acordo com o modelo estabelecido?	X		
	16. ILUSTRAÇÕES (figuras, quadros, tabelas) As ilustrações são legíveis e obedecem às normas da ABNT?		X	
	17. REFERÊNCIAS E CITAÇÕES As referências obedecem às normas da ABNT?		X	
	As citações obedecem às normas da ABNT?	X		
	Todos os documentos citados foram referenciados e vice-versa, isto é, as citações e referências são consistentes?	X		

8.1.1



UNIVERSIDADE REGIONAL DE BLUMENAU
CENTRO DE CIÊNCIAS EXATAS E NATURAIS
DISCIPLINA: TRABALHO DE CONCLUSÃO DE CURSO I
CURSO: CIÊNCIA DA COMPUTAÇÃO - BCC

ATA DA DEFESA: BANCA DO PRÉ-PROJETO

Venho, por meio deste, manifestar minha avaliação sobre a **apresentação** do Pré-Projeto de TCC realizado pelo(a) acadêmico(a), **_ Jeferson Bonecher _** no **PRIMEIRO SEMESTRE DE 2023**, com o título **_ ANÁLISE COMPARATIVA DE ALGORITMOS DE MACHINE LEARNING PARA A PREVISÃO DE VALOR DAS AÇÕES NA BOLSA DE VALORES _**, sob orientação do prof(a). **_ Marcel Hugo _**.

A referida apresentação obteve a seguinte nota:

Componente da Banca	Nota (de 0 a 10)
Professor(a) Avaliador(a): _ Aurélio Faustino Hoppe _	8,0

ATENÇÃO. A nota acima se refere somente a apresentação do pré-projeto e vai ser repassada para o aluno (orientando). Favor preencher os campos acima e enviar por e-mail ao professor de TCC1 (dalton@furb.br). Não passar o arquivo com as anotações da revisão já enviado ao professor de TCC1 para o orientando e nem para o professor orientador. Após o professor de TCC1 receber esta ata preenchida, o professor de TCC1 vai disponibilizar para o orientando/orientador os arquivos com as revisões. Caso julgue necessário fazer mais alguma consideração relacionada ao pré-projeto ou a defesa, favor usar o espaço abaixo.

Observações da apresentação:



ATA DA DEFESA: BANCA DO PRÉ-PROJETO

Venho, por meio deste, manifestar minha avaliação sobre a **apresentação** do Pré-Projeto de TCC realizado pelo(a) acadêmico(a), **_ Jeferson Bonecher _** no **PRIMEIRO SEMESTRE DE 2023**, com o título **_ ANÁLISE COMPARATIVA DE ALGORITMOS DE MACHINE LEARNING PARA A PREVISÃO DE VALOR DAS AÇÕES NA BOLSA DE VALORES _**.

A referida apresentação obteve a seguinte nota:

Componente da Banca	Nota (de 0 a 10)
Professor(a) Orientador(a): _ Marcel Hugo _	9,5

A apresentação aconteceu em 02/06 / 2023 na sala de reunião virtual do MS-Teams, tendo início às 16h40 e foi encerrada às 17h04.

ATENÇÃO. A nota acima se refere somente a apresentação do pré-projeto e vai ser repassada para o aluno (orientando). Favor preencher os campos acima e enviar por e-mail ao professor de TCC1 (dalton@furb.br). Lembro que os arquivos com as anotações das revisões do professor de TCC1 e Avaliador serão enviados para o orientando e professor orientador após o professor de TCC1 receber esta ata preenchida. Caso julgue necessário fazer mais alguma consideração relacionada ao pré-projeto ou a defesa, favor usar o espaço abaixo.

Observações da apresentação: